

Projeto Final MC970 - Paralelização da Técnicas de Meios-Tons

Vinicius P. M. Miguel - RA260731
Henrique Pareda de Souza - RA260497
Raphael Salles Vitor de Souza - RA223641

30 de junho de 2025

Sumário

1	Introdução	1
2	Formulação	2
2.1	Difusão de Erro	2
2.2	Difusão de Erro Estocástica	3
3	Implementação	4
3.1	Versão Serial	4
3.2	Versão Paralela com OpenMP	4
3.3	Versão em CUDA	4
3.4	Implementação de Métodos Estocásticos	4
3.5	Análise de WSNR	5
4	Speedup	5
4.1	Método estocástico	6
5	Conclusão	8
Referências		9

1 Introdução

A técnica de meios tons (*halftone*) consiste na redução de uma imagem monocromática de 256 níveis de cinza para pixels brancos e pretos, de forma que a imagem resultante fique visualmente parecida com a entrada. Um exemplo de aplicação dessa técnica pode ser visto na Figura 1, em que a imagem mantém a estrutura visual, porém com menos níveis de informação. Isto é útil, por exemplo, em cenários em que deseja-se economizar armazenamento, com pouco prejuízo de perda de informação visual. Este método também pode ser utilizado em imagens coloridas, onde a técnica é aplicada separadamente em cada canal de cor.



Imagen original



Imagen com meios tons

Figura 1: Comparação entre a imagem original e a imagem após aplicação da técnica de meios tons.

O presente trabalho tem como objetivo a paralelização de algoritmos de meios tons baseados em difusão de erro. A difusão de erro é uma técnica que distribui o erro de quantização dos pixels vizinhos, permitindo uma melhor representação visual da imagem original. A paralelização desses algoritmos pode melhorar significativamente o desempenho, especialmente em imagens de alta resolução.

Estabelece-se, portanto, como objetivo específico deste trabalho a comparação do desempenho entre as versões serial, OpenMP e CUDA de seis algoritmos consagrados na literatura: Floyd & Steinberg; Stevenson & Arce; Burkes; Sierra; Stucki; e Jarvis Judice & Ninke.

2 Formulação

2.1 Difusão de Erro

Dada uma imagem com 255 níveis de cinza, nosso objetivo é aplicar um algoritmo que gere uma nova imagem contendo apenas pixels pretos e brancos, de modo que o resultado final seja visualmente semelhante à imagem original. Esse procedimento pode ser realizado tanto em imagens monocromáticas quanto coloridas. No caso de imagens coloridas, o algoritmo é aplicado individualmente a cada canal de cor, convertendo o valor de cada pixel em cada canal para preto (0) ou para o valor máximo (255).

Algorithm 1 Algoritmo Geral de Halftone por Difusão de Erro

```

1: for all canal ∈ Imagem A do
2:   for x = 0 até m - 1 do
3:     for y = 0 até n - 1 do
4:       if A(x, y, canal) < 128 then
5:         B(x, y, canal) = 0
6:       else
7:         B(x, y, canal) = 255
8:       end if
9:
10:      erro = A(x, y, canal) - B(x, y, canal)
11:      DistribuirErro(A, matrizDifusao, erro)
12:    end for
13:  end for
14: end for

```

As matrizes de difusão de erro são estruturas que determinam como o erro de quantização de um pixel é distribuído para seus vizinhos ainda não processados. Cada método de difusão utiliza uma matriz diferente, cujos valores representam a fração do erro a ser repassada para cada pixel vizinho. O objetivo é espalhar o erro de forma controlada, minimizando artefatos visuais e mantendo a aparência da imagem original.

Por exemplo, na matriz de Floyd e Steinberg, o erro é distribuído para quatro pixels vizinhos, com diferentes pesos, enquanto métodos como Jarvis, Judice e Ninke distribuem o erro para um número maior de vizinhos, suavizando ainda mais a transição dos tons. A escolha da matriz influencia diretamente o resultado visual do halftone e o desempenho do algoritmo.

$$A(x, y) = \text{matrizDifusao}(x, y) + (x, y) \cdot \text{erro} \quad (1)$$

Neste projeto, analisamos seis métodos clássicos de difusão de erro: Floyd e Steinberg, Stevenson e Arce, Burkes, Sierra, Stucki e Jarvis, Judice e Ninke. As matrizes de difusão associadas a cada método estão apresentadas nas Tabelas 1 a 6, onde $f(x, y)$ representa o pixel corrente $A(x, y, canal)$. Cada matriz define como o erro de quantização é distribuído entre os vizinhos, influenciando diretamente o resultado visual do halftone.

	$f(x, y)$	7 / 16
3 / 16	5 / 16	1 / 16

Tabela 1: Floyd e Steinberg

		$f(x, y)$		32 / 200	
12 / 200		26 / 200		30 / 200	
	12 / 200		26 / 200		12 / 200
5 / 200		12 / 200		12 / 200	5 / 200

Tabela 2: Stevenson e Arce

		$f(x, y)$	8 / 32	4 / 32
2 / 32	4 / 32	8 / 32	4 / 32	2 / 32

Tabela 3: Burkes

		$f(x, y)$	5 / 32	3 / 32
2 / 32	4 / 32	5 / 32	4 / 32	2 / 32
	2 / 32	3 / 32	2 / 32	

Tabela 4: Sierra

		$f(x, y)$	8 / 42	4 / 42
2 / 42	4 / 42	8 / 42	4 / 42	2 / 42
1 / 42	2 / 42	4 / 42	2 / 42	1 / 42

Tabela 5: Stucki

		$f(x, y)$	7 / 48	5 / 48
3 / 48	5 / 48	7 / 48	5 / 48	3 / 48
1 / 48	3 / 48	5 / 48	3 / 48	1 / 48

Tabela 6: Jarvis, Judice e Ninke

2.2 Difusão de Erro Estocástica

O método estocástico de difusão de erro introduz um elemento de aleatoriedade no processo tradicional de dithering. Diferente do método determinístico, que distribui o erro de quantização com base em uma matriz fixa de pesos, o método estocástico modifica a quantidade de erro difundido com base em um fator aleatório. Essa abordagem visa reduzir padrões visuais repetitivos e suavizar artefatos que podem surgir em regiões uniformes da imagem.

A implementação consiste em adicionar um ruído aleatório controlado ao valor do erro antes de sua distribuição. Formalmente, seja e o erro de quantização de um pixel, e $r \sim \mathcal{U}(-p, p)$ um valor extraído de uma distribuição uniforme, com $p \in [0, 1]$ sendo um parâmetro de controle da aleatoriedade. O erro ajustado e' é então dado por:

$$e' = e \cdot (1 + r)$$

Esse erro ajustado e' é então distribuído normalmente conforme a matriz de difusão escolhida (por exemplo, Floyd-Steinberg), mantendo a estrutura do algoritmo original. O valor de p pode ser ajustado para controlar a intensidade da estocasticidade. Valores menores de p resultam em comportamento mais próximo ao determinístico, enquanto valores maiores aumentam a variação aleatória.

Além de seus possíveis benefícios visuais, o método estocástico apresentou desempenho competitivo nas versões paralelas, conforme descrito na Seção 4.1 do relatório.

3 Implementação

Neste capítulo, apresentamos as três versões do código desenvolvidas para fins comparativos: uma versão serial, uma versão paralelizada utilizando OpenMP e uma versão implementada em CUDA. Cada uma dessas versões será explicada em detalhes nas subseções a seguir.

3.1 Versão Serial

A versão serial do código, localizada no arquivo `serial.cpp`, foi implementada como ponto de partida para o desenvolvimento das versões paralelas. Nesta implementação, o algoritmo é executado de forma sequencial, processando os dados de entrada um elemento por vez. Essa abordagem é simples e direta, mas não aproveita os recursos de paralelismo disponíveis em arquiteturas modernas.

O código foi estruturado para ser claro e modular, facilitando a compreensão e a posterior paralelização. Ele realiza as seguintes etapas principais:

- Leitura dos dados de entrada.
- Processamento sequencial dos dados, aplicando a técnica de meios-tons utilizando difusão de erro.
- Escrita dos resultados no arquivo de saída.

O algoritmo de difusão de erro utilizado na versão serial é configurado para suportar diferentes métodos de dithering, como Floyd-Steinberg, Burkes, Sierra, entre outros. A escolha do método é feita com base em um parâmetro de entrada, permitindo flexibilidade na execução.

Essa versão serve como base para medir o desempenho inicial e comparar os ganhos obtidos com as versões paralelas. O código completo da implementação pode ser encontrado abaixo:

3.2 Versão Paralela com OpenMP

A versão paralela utilizando OpenMP foi desenvolvida a partir da versão serial, com o objetivo de explorar o paralelismo em CPUs multicore. O código-fonte desta versão é essencialmente o mesmo da versão serial, diferindo apenas pela inclusão de diretivas de paralelização do OpenMP, que são ativadas em tempo de compilação. Os resultados e o impacto dessas alterações serão discutidos na Seção 4.

3.3 Versão em CUDA

A versão em CUDA, que será implementada no futuro, tem como objetivo explorar o paralelismo massivo oferecido por GPUs. Esta subseção será preenchida com os detalhes da implementação assim que o código estiver concluído.

3.4 Implementação de Métodos Estocásticos

Além das versões mencionadas anteriormente, também foram implementados métodos estocásticos para avaliar como o uso de aleatoriedade pode impactar o resultado visual da técnica de meios-tons. Esses métodos introduzem variações aleatórias no processo de difusão de erro, com o objetivo de verificar se a qualidade visual das imagens processadas é significativamente alterada.

A implementação dos métodos estocásticos foi realizada adicionando um fator de ruído controlado ao cálculo da difusão de erro. Esse fator é gerado utilizando uma distribuição uniforme, garantindo que o comportamento do algoritmo permaneça previsível e reproduzível. As etapas principais dessa abordagem são as seguintes:

- Geração de um valor aleatório para cada pixel, dentro de um intervalo predefinido.
- Ajuste do erro difundido com base no valor aleatório gerado.
- Continuação do processamento com o erro ajustado.

Para as versões paralelas, foram adicionadas flags específicas para habilitar o suporte aos métodos estocásticos:

- Na versão OpenMP, a flag `-stochastic` foi utilizada durante a compilação para ativar o código relacionado aos métodos estocásticos. O comportamento estocástico pode ser controlado por um parâmetro de entrada, permitindo escolher entre dithering estocástico (1) ou padrão (0), sendo o padrão o valor 1.

- Na versão CUDA, a flag `-stochastic` também foi empregada, garantindo que o comportamento estocástico fosse incorporado ao kernel CUDA. Assim como na versão OpenMP, o parâmetro de entrada permite alternar entre dithering estocástico (1) ou padrão (0), com o valor padrão definido como 1.

Apesar de introduzir aleatoriedade no processo, os resultados preliminares indicam que o impacto visual é mínimo, especialmente em imagens com alta resolução. Isso sugere que os métodos estocásticos podem ser uma alternativa viável para cenários onde a uniformidade do padrão de dithering não é uma prioridade.

A análise detalhada dos resultados obtidos com os métodos estocásticos será apresentada na Seção 4, onde compararemos a qualidade visual e o desempenho em relação às outras versões do código.

3.5 Análise de WSNR

Para avaliar a qualidade das imagens processadas pelas diferentes versões do código, utilizamos o script `wsnr.py`, que calcula a métrica WSNR (Weighted Signal-to-Noise Ratio). Essa métrica é amplamente utilizada para medir a qualidade de imagens processadas, levando em consideração o ruído introduzido durante o processamento.

A seguir, apresentamos os resultados obtidos para cada método (serial, OpenMP e CUDA), organizados por tamanho de imagem:

Tabela de Resultados WSNR por Método e Tamanho de Imagem

Tamanho	Imagen	CUDA (dB)	OpenMP (dB)	Serial (dB)
Small	small_1	0.6595	-0.1043	-0.1279
	small_2	1.1523	0.6237	0.5631
Medium	medium_1	1.2968	0.8956	0.9051
	medium_2	1.2322	0.9434	0.8777
	medium_3	0.6089	0.2502	0.2566
	medium_4	0.7146	0.3194	0.2924
	medium_5	1.7778	0.7717	0.7879
	medium_6	1.3159	0.8904	0.8921
	medium_7	1.2963	0.7031	0.6980
	medium_8	-0.2986	-0.8768	-0.8693
Large	large_1	0.0847	-0.0862	-0.0905
	large_2	1.6083	0.8550	0.8642
	large_3	1.6087	0.8773	0.8754
	large_4	0.7675	0.7062	0.6588
	large_5	-0.3377	-0.8666	-0.8857
Xlarge	xlarge_1	1.6322	0.8531	0.8586
	xlarge_2	1.6904	0.9132	0.9014
	xlarge_3	1.6817	0.8648	0.8632
	xlarge_4	1.6876	0.9090	0.9010
	xlarge_5	0.7856	0.4889	0.4997
	xlarge_6	2.3256	1.3715	1.3500
	xlarge_7	0.8412	0.1943	0.2099
Média WSNR		1.0969	0.5226	0.5128

Tabela 7: Resultados WSNR por Método e Tamanho de Imagem

Interpretação dos Resultados

A métrica WSNR indica a relação entre o sinal e o ruído introduzido no processamento das imagens. Valores mais altos de WSNR indicam menor degradação da qualidade da imagem. Observa-se que a versão CUDA apresenta a maior média de WSNR (1.0969 dB), seguida pela versão OpenMP (0.5226 dB) e pela versão serial (0.5128 dB). Isso sugere que a versão CUDA não apenas é mais eficiente em termos de desempenho, mas também preserva melhor a qualidade das imagens processadas.

4 Speedup

Nesta seção, apresentamos as métricas de Speedup obtidas durante os experimentos. O Speedup é calculado como a razão entre o tempo de execução da versão serial e o tempo de execução das versões paralelas (OpenMP e CUDA). Foram consideradas duas abordagens principais:

- **Speedup por Método:** Para cada método de dithering (*FloydSteinberg*, *StevensonArce*, *Burkes*, *Sierra*, *Stucki*, *JarvisJudiceNinke*), calculamos o Speedup médio considerando todas as imagens processadas.
- **Speedup por Tamanho de Imagem:** Para cada tamanho de imagem (e.g., 1920x1080, 1280x720), calculamos o Speedup médio considerando todos os métodos de dithering aplicados. Os tamanhos de imagem foram classificados em quatro categorias:
 - **Pequeno (small):** Imagens com largura e altura menores ou iguais a 256 pixels.
 - **Médio (medium):** Imagens com largura e altura menores ou iguais a 512 pixels.
 - **Grande (large):** Imagens com largura e altura menores ou iguais a 1024 pixels.
 - **Muito Grande (xlarge):** Imagens com largura ou altura maiores que 1024 pixels.

Os resultados obtidos estão destacados nas Tabelas 8 e 9. Os campos em vermelho indicam os valores que ainda precisam ser preenchidos com os dados experimentais.

Tabela 8: Resultados de Speedup por Método

Método	Serial (ms)	OpenMP (ms)	CUDA (ms)	Speedup OpenMP	Speedup CUDA
FloydSteinberg	126.52 ± 301.72	25.08 ± 47.89	146.27 ± 317.29	5.04 ± 15.41	0.86 ± 2.79
StevensonArce	x.xx	x.xx	x.xx	x.xx	x.xx
Burkes	x.xx	x.xx	x.xx	x.xx	x.xx
Sierra	x.xx	x.xx	x.xx	x.xx	x.xx
Stucki	x.xx	x.xx	x.xx	x.xx	x.xx
JarvisJudiceNinke	x.xx	x.xx	x.xx	x.xx	x.xx

Tabela 9: Resultados de Speedup por Tamanho de Imagem

Tamanho da Imagem	Serial (ms)	OpenMP (ms)	CUDA (ms)	Speedup OpenMP	Speedup CUDA
Small	4.57 ± 0.78	3.81 ± 2.81	7.76 ± 0.95	1.20 ± 0.91	0.59 ± 0.12
Medium	21.20 ± 0.78	7.71 ± 3.25	30.65 ± 2.33	2.75 ± 1.16	0.69 ± 0.08
Large	37.90 ± 19.62	10.66 ± 4.04	58.64 ± 26.64	3.56 ± 2.06	0.65 ± 0.45
Extra Large	345.02 ± 486.16	61.30 ± 75.79	380.57 ± 507.17	5.63 ± 8.30	0.91 ± 1.76

Tabela 10: Resultados de Eficiência por Método

Método	Eficiência OpenMP	Eficiência CUDA
FloydSteinberg	x.xx	x.xx
StevensonArce	x.xx	x.xx
Burkes	x.xx	x.xx
Sierra	x.xx	x.xx
Stucki	x.xx	x.xx
JarvisJudiceNinke	x.xx	x.xx

Tabela 11: Resultados de Eficiência por Tamanho de Imagem

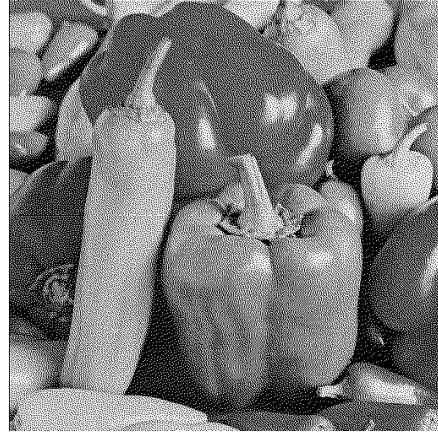
Tamanho da Imagem	Eficiência OpenMP	Eficiência CUDA
800x600	x.xx	x.xx
1280x720	x.xx	x.xx
1920x1080	x.xx	x.xx

4.1 Método estocástico

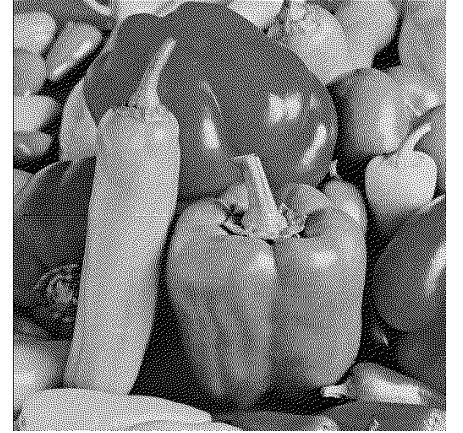
Os códigos de OpenMP e CUDA possuíam uma flag que permitia a utilização de um método estocástico. Esse método introduz variações aleatórias no processo de dithering, o que pode impactar os resultados de Speedup e Eficiência. Durante os experimentos, observamos que o uso do método estocástico gerou diferenças nos tempos de execução e nos resultados finais. No entanto, como o objetivo do processo de dithering é criar um efeito visual na imagem, essas variações não comprometem a qualidade visual do resultado, tornando válida a sua utilização.



(a) Imagem Original



(b) OpenMP



(c) OpenMP Estocástico

Figura 2: Comparação visual entre as imagens: original, OpenMP e OpenMP com método estocástico.

Conferir se a implementacao do estocástico está correta

Os resultados obtidos com o método estocástico foram considerados satisfatórios. Apesar das variações introduzidas no processo de dithering, a qualidade visual das imagens geradas permaneceu consistente com os objetivos do experimento. A Figura 2 ilustra que as diferenças visuais entre as imagens processadas com e sem o método estocástico são mínimas, reforçando a validade do uso dessa abordagem nos experimentos realizados.

Diferente de antes, vamos apresentar os resultados sem levar em consideração à incerteza associada, a fim de evitar a redundância de informação sobre as diferenças dos tamanhos de imagens. É aceitável que os resultados sejam apresentados sem considerar a incerteza, uma vez que o foco é comparar os métodos de dithering e suas implementações paralelas de forma geral.

Tabela 12: Tempos Médios de Execução para o Método Estocástico

Método	Serial (s)	OpenMP (s)	CUDA (s)
FloydSteinberg	x.xx	x.xx	x.xx
StevensonArce	x.xx	x.xx	x.xx
Burkes	x.xx	x.xx	x.xx
Sierra	x.xx	x.xx	x.xx
Stucki	x.xx	x.xx	x.xx
JarvisJudiceNinke	x.xx	x.xx	x.xx

Como o tempo de execução do método estocástico do serial foi muito maior que a implementação comum, vamos utilizar a implementação não estocástica como base para o cálculo do Speedup e Eficiência.

Tabela 13: Speedup para o Método Estocástico

Método	Speedup OpenMP	Speedup CUDA
FloydSteinberg	x.xx	x.xx
StevensonArce	x.xx	x.xx
Burkes	x.xx	x.xx
Sierra	x.xx	x.xx
Stucki	x.xx	x.xx
JarvisJudiceNinke	x.xx	x.xx

Tabela 14: Resultados de Eficiência para o Método Estocástico

Método	Eficiência OpenMP	Eficiência CUDA
FloydSteinberg	x.xx	x.xx
StevensonArce	x.xx	x.xx
Burkes	x.xx	x.xx
Sierra	x.xx	x.xx
Stucki	x.xx	x.xx
JarvisJudiceNinke	x.xx	x.xx

5 Conclusão

Referências